Optimización en Ciencia de Datos

Clase 1: el aprendizaje automático como problema de optimización

Pablo A. Lotito Victoria Orlando

Modelización Matemática
Facultad de Ciencias Exactas – UNCPBA

2.º cuatrimestre 2026









Objetivos de la clase de hoy

- Formular problemas de ML como problemas de optimización.
- Entender el rol de la convexidad.
- Analizar condiciones de optimalidad.
- Interpretar regularización y restricciones.
- Releer, con problemas de datos, la teoría que ya construimos en la materia.

Puente con lo que ya vimos en Modelización

Lo que ya vimos	Unidad	Para qué lo usamos hoy
Conjuntos y funciones convexas, epigrafo	U1–U3	Reconocer cuándo entrenar es "fácil"
Condiciones de primer y segundo orden	U3–U4	Resolver Ridge en forma cerrada
Óptimo local = global en el caso convexo	U4	Garantías del entrenamiento convexo
Cono normal: $-\nabla f(x^\star) \in N_F(x^\star)$	U5	Optimalidad con restricciones
Subdiferencial y $0 \in \partial f(x^\star)$	U6	Optimalidad de Lasso (no diferenciable)
Lagrangiano, KKT, Slater, dualidad	U9	Regularización como restricción

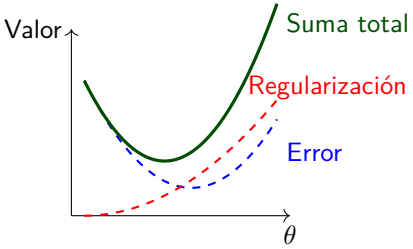
La idea de la clase

No hay teoría nueva: hay un **problema nuevo**, el de ajustar un modelo a datos. Las diapositivas marcadas con Visto en Uk son repaso.

Entrenar un modelo = Resolver un problema variacional

Dado un conjunto de datos $\{(x_i, y_i)\}_{i=1}^n$, entrenar consiste en resolver:

$$\theta^\star \in \arg\min_{\theta \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^{n} \ell(y_i, f_\theta(x_i)) + \lambda R(\theta).$$

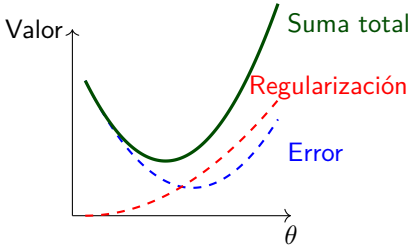


- error (o pérdida) del modelo sobre los datos.
- término de regularización que penaliza soluciones "grandes" o "complejas", ayudando a evitar el *overfitting* (sobreajuste).

Entrenar un modelo = Resolver un problema variacional

Dado un conjunto de datos $\{(x_i, y_i)\}_{i=1}^n$, entrenar consiste en resolver:

$$\theta^\star \in \arg\min_{\theta \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^{n} \ell(y_i, f_\theta(x_i)) + \lambda R(\theta).$$



- error (o pérdida) del modelo sobre los datos.
- término de regularización que penaliza soluciones "grandes" o "complejas", ayudando a evitar el *overfitting* (sobreajuste).

- Problema de alta dimensión.
- Posiblemente no convexo.
- Con estructura estadística.

Estructura del problema

¿Qué propiedades del problema determinan su comportamiento?

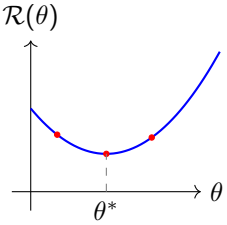
- Existencia de solución.
- Unicidad.
- Estabilidad ante perturbaciones.
- Tasa de convergencia de algoritmos.

Estas propiedades dependen principalmente de la **geometría** de la función objetivo.

El problema de optimización

Dado un conjunto de datos $\{(x_i, y_i)\}_{i=1}^n$,

$$\mathcal{R}(\theta) = \frac{1}{n}\sum_{i=1}^{n} \ell(y_i, f_\theta(x_i)) + \lambda R(\theta) \longrightarrow \theta^\star \in \underset{\theta \in \mathbb{R}^p}{\arg\min}\, \mathcal{R}(\theta).$$

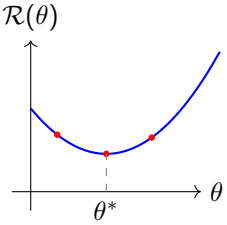


Entrenamiento = buscar el mínimo de la función objetivo.

El problema de optimización

Dado un conjunto de datos $\{(x_i, y_i)\}_{i=1}^n$,

$$\mathcal{R}(\theta) = \frac{1}{n}\sum_{i=1}^{n} \ell(y_i, f_\theta(x_i)) + \lambda R(\theta) \longrightarrow \theta^\star \in \underset{\theta \in \mathbb{R}^p}{\arg\min}\, \mathcal{R}(\theta).$$



Entrenamiento = buscar el mínimo de la función objetivo.

Todo el comportamiento del modelo depende de la geometría de esta función.

Notación

$$\begin{array}{ll} \text{minimizar} & f_0(x) \\ \text{sujeto a} & f_i(x) \leq b_i, \qquad i = 1, \ldots, m \end{array}$$

- $x = (x_1, \ldots, x_n)$: variables
- $f_0 : \mathbb{R}^n \to \mathbb{R}$: función objetivo
- $f_i : \mathbb{R}^n \to \mathbb{R},\ i = 1, \ldots, m$: restricciones

- **Conjunto factible** $F = \{x \in \mathbb{R}^n \mid f_i(x) \leq b_i, \qquad i = 1, \ldots, m\}$.
- **Valor óptimo** $p^\star = \inf_{x \in F} f_0(x)$.
- **Solución optima** $x^\star$, si $f_0(x^\star) = p^\star$, puede haber varias o ninguna.

$$p^\star = f_0(x^\star) \leq f_0(x), \quad \forall x \in F.$$

Resolución de un PO

Anteriormente

- Lineal = fácil
- No lineal = Dificil

Actualmente

- Convexo = fácil
- No convexo = Dificil

- Existen muchos algoritmos diferentes (disponibles en diversas plataformas):
  - métodos de punto interior para hasta decenas de miles de variables,
  - métodos de primer orden para problemas aún más grandes,
  - no requieren punto inicial, babysitting, ni ajuste fino.
- Se puede desarrollar y desplegar rápidamente utilizando lenguajes de modelado (GAMS, AMPL, Pyomo, CVXPY, etc.).
- Los solvers son confiables y se pueden embeber.
- La generación de código produce solvers en tiempo real que ejecutan en milisegundos (por ejemplo, en Falcon 9 y Heavy para el aterrizaje). Es decir, se pueden resolver problemas de optimización convexos en tiempo real.

Historia de PO convexos

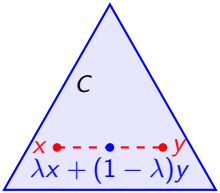
Breve historia de la optimización convexa

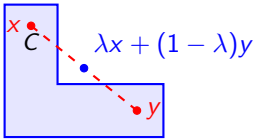
- **Teoría (análisis convexo):** 1900–1970
- **Algoritmos**
  - 1947: algoritmo símplex para programación lineal (Dantzig)
  - Años 1960: primeros métodos de punto interior (Fiacco & McCormick, Dikin, ...)
  - Años 1970: método del elipsoide y otros métodos de subgradiente
  - Años 1980 y 90: métodos de punto interior modernos (Karmarkar, Nesterov & Nemirovski)
  - Desde los 2000s: muchos métodos nuevos para optimización convexa a gran escala
- **Aplicaciones**
  - Antes de 1990: principalmente en investigación operativa, algunos en ingeniería
  - Desde 1990: muchas aplicaciones en ingeniería (control, procesamiento de señales, comunicaciones, diseño de circuitos, ...)
  - Desde los 2000s: aprendizaje automático, estadística, finanzas

Convexidad de conjuntos

Un conjunto $C \subseteq \mathbb{R}^n$ es convexo si

$$x, y \in C, \quad \lambda \in [0,1] \Rightarrow \lambda x + (1-\lambda)y \in C.$$



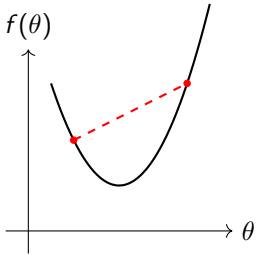


Propiedades básicas:

- La intersección de convexos es convexa
- La unión de convexos no necesariamente es convexa.

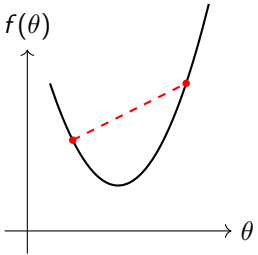
Convexidad de funciones

Si el segmento que une dos puntos del gráfico queda por encima de la función, la función es **convexa**.

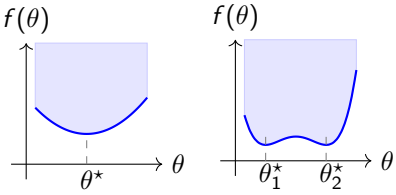


Convexidad de funciones

Si el segmento que une dos puntos del gráfico queda por encima de la función, la función es **convexa**.



O de manera equivalente: el ***epigrafo*** es un conjunto convexo.



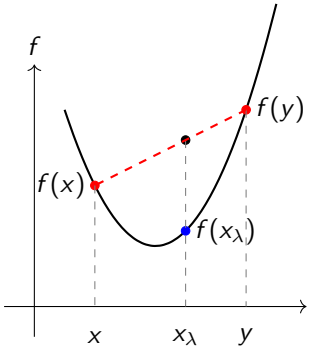
Definición formal de convexidad

Definición

Una función $f : \mathbb{R}^p \to \mathbb{R}$ es convexa si:

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda) f(y).$$

$\forall x, y, \forall \lambda \in [0, 1]$.



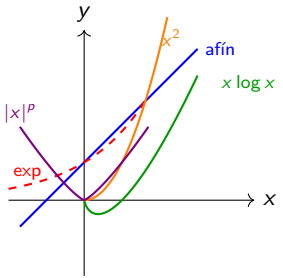
Funciones convexas y cóncavas

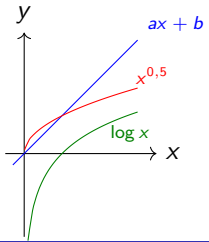
Convexas:

- afín: $ax + b$ en $\mathbb{R}$, para todo $a, b \in \mathbb{R}$
- exponencial: e^{ax}, para todo $a \in \mathbb{R}$
- potencias: x^α en $\mathbb{R}_{++}$, si $\alpha \geq 1$ o $\alpha \leq 0$
- potencias de valor absoluto: $|x|^p$ en $\mathbb{R}$, si $p \geq 1$
- entropía negativa: $x \log x$ en $\mathbb{R}_{++}$

Cóncavas ($-f$ es convexa):

- afín: $ax + b$ en $\mathbb{R}$, para todo $a, b \in \mathbb{R}$
- potencias: x^α en $\mathbb{R}_{++}$, si $0 \leq \alpha \leq 1$
- logaritmo: $\log x$ en $\mathbb{R}_{++}$



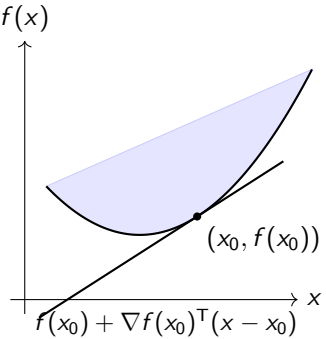


Condiciones de convexidad - Primer orden

Si f es diferenciable y $\operatorname{dom} f$ es convexo, entonces

f es convexa $\iff$ $f(y) \geq f(x) + \nabla f(x)^{\mathsf{T}}(y - x) \quad \forall\, x, y \in \operatorname{dom} f.$

- La recta/plano tangente en x es un **subestimador global**.
- En 1D: $f(y) \geq f(x) + f'(x)(y - x)$.



Condiciones de segundo orden

Para f dos veces diferenciable el Hessiano $\nabla^2 f(x)$ es una matriz

$$(\nabla^2 f(x))_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}, \quad i, j = 1, \ldots, n,$$

Condiciones de segundo orden: para f dos veces diferenciable con dominio convexo:

- f es convexa si y solo si $\nabla^2 f(x) \succeq 0$ para todo $x \in \operatorname{dom} f$.
- Si $\nabla^2 f(x) \succ 0$ para todo $x \in \operatorname{dom} f$, entonces f es estrictamente convexa.

Ejemplos:

función cuadrática: $f(x) = \frac{1}{2}x^T Px + q^T x + r \quad (\text{con } P \in S^n)$

$$\nabla f(x) = Px + q, \qquad \nabla^2 f(x) = P$$

Convexa si $P \succeq 0$.

objetivo de mínimos cuadrados: $f(x) = \|Ax - b\|_2^2$

$$\nabla f(x) = 2A^T(Ax - b), \qquad \nabla^2 f(x) = 2A^T A$$

Convexa (para cualquier A).

¿Está bien esto?

Ejemplo: función cuadrática sobre lineal: $f(x, y) = \frac{x^2}{y}$

$$\nabla f(x, y) = \begin{bmatrix} \frac{2x}{y} \\ -\frac{x^2}{y^2} \end{bmatrix}; \quad \nabla^2 f(x, y) = \frac{2}{y^3} \begin{bmatrix} y^2 & -2xy \\ -2xy & x^2 \end{bmatrix}$$

Esta matriz es semidefinida positiva $\forall\, y > 0$, por lo que $f(x, y)$ es convexa para $y > 0$.

Cómo verificar la convexidad

1. Verificar la definición (a menudo simplificado restringiéndose a una recta).
2. Si la función es dos veces diferenciable, ver que $\nabla^2 f(x) \succeq 0$.
3. Mostrar que f se obtiene a partir de funciones convexas simples mediante operaciones que preservan la convexidad:
   - Suma ponderada con coeficientes no negativos
   - Composición con función afín
   - Máximo puntual y supremo
   - Bajo ciertas condiciones: composición, minimización y perspectiva.

Problema de optimización en forma estándar

Problema de optimización en forma estándar

$$\begin{aligned} \text{minimizar} \quad & f_0(x) \\ \text{sujeto a} \quad & f_i(x) \leq 0, \quad i = 1, \ldots, m \\ & h_i(x) = 0, \quad i = 1, \ldots, p \end{aligned}$$

- $x \in \mathbb{R}^n$ es la variable de optimización
- $f_0 : \mathbb{R}^n \to \mathbb{R}$ es la función objetivo
- $f_i : \mathbb{R}^n \to \mathbb{R}$, $i = 1, \ldots, m$, son restricciones de desigualdad
- $h_i : \mathbb{R}^n \to \mathbb{R}$ son restricciones de igualdad

Valor óptimo:

$$p^\star = \text{ínf}\{f_0(x) \mid f_i(x) \leq 0,\ i = 1, \ldots, m,\ h_i(x) = 0,\ i = 1, \ldots, p\}$$

$p^\star = +\infty$ si el problema es **infactible** (ningún x satisface las restricciones)
$p^\star = -\infty$ si el problema es **no acotado inferiormente**

Óptimo y óptimo local

x **es factible** si $x \in \operatorname{dom} f_0$ y satisface las restricciones.

x **es óptimo** (óptimo global) si $f_0(x) = p^\star$; X_{opt} es el conjunto de puntos óptimos.

x **es óptimo local** si existe $R > 0$ tal que x es óptimo para el siguiente problema:

$$\begin{array}{ll} \min\limits_{z} & f_0(z) \\ \text{s. a} & f_i(z) \leq 0, \quad i = 1, \ldots, m, \\ & h_i(z) = 0, \quad i = 1, \ldots, p, \\ & \|z - x\|_2 \leq R \end{array}$$

Ejemplos (con $n = 1$, $m = p = 0$):

- $f_0(x) = 1/x$, $\operatorname{dom} f_0 = \mathbb{R}_+$; $p^\star = 0$, no hay punto óptimo
- $f_0(x) = -\log x$, $\operatorname{dom} f_0 = \mathbb{R}_+$; $p^\star = -\infty$
- $f_0(x) = x \log x$, $\operatorname{dom} f_0 = \mathbb{R}_+$; mínimo en $x = 1/e$, $x = 1/e$ es óptimo
- $f_0(x) = x^3 - 3x$, $p^\star = -\infty$, óptimo local en $x = 1$

Restricciones implícitas

El problema de optimización en forma estándar tiene una **restricción implícita**:

$$x \in \mathcal{D} = \bigcap_{i=0}^{m} \operatorname{dom} f_i \ \cap \ \bigcap_{i=1}^{p} \operatorname{dom} h_i,$$

- Llamamos $\mathcal{D}$ al **dominio** del problema.
- Las restricciones $f_i(x) \leq 0$, $h_i(x) = 0$ son las restricciones **explícitas**.
- Un problema es **no restringido** si no tiene restricciones explícitas ($m = p = 0$).

Ejemplo:
Minimizar

$$f_0(x) = -\sum_{i=1}^{k} \log\left(b_i - a_i^T x\right)$$

es un problema no restringido con **restricciones implícitas** $a_i^T x < b_i$.

Problema de optimización convexa

Forma estándar de un problema de optimización convexa

$$\begin{array}{ll} \text{minimizar} & f_0(x) \\ \text{s. a} & f_i(x) \leq 0, \quad i = 1, \ldots, m, \\ & a_i^T x = b_i, \quad i = 1, \ldots, p \end{array}$$

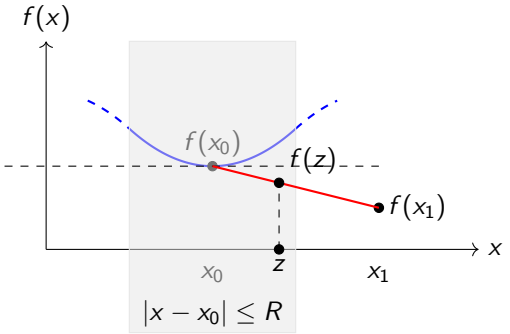
$f_0, f_1, \ldots, f_m$ son funciones convexas; las restricciones de igualdad son afines.
En forma vectorial:

$$\begin{array}{ll} \text{minimizar} & f_0(x) \\ \text{s. a} & f_i(x) \leq 0, \quad i = 1, \ldots, m, \\ & Ax = b \end{array}$$

Propiedad importante: el conjunto factible de un problema de optimización convexa es convexo.

Óptimos locales y globales

Todo optimizador local de un problema convexo es optimizador global.
Demostración: Sea x_0 óptimo local, y sea x_1 factible tal que $f_0(x_1) < f_0(x_0)$.

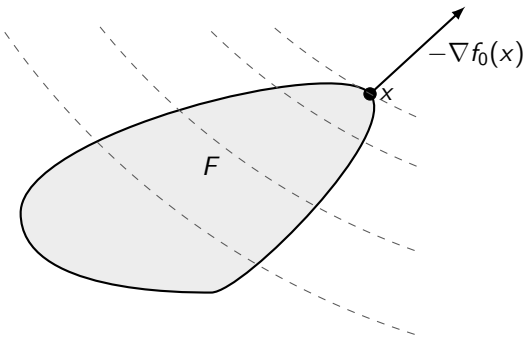


Si además f es estrictamente convexa: $f(\lambda x + (1-\lambda)y) < \lambda f(x) + (1-\lambda) f(y)$ el mínimo es único.

Criterio de optimalidad para f_0 diferenciable

$x \in F$ es óptimo si y solo si

$$\nabla f_0(x)^T (y - x) \geq 0 \qquad \forall y \in F$$

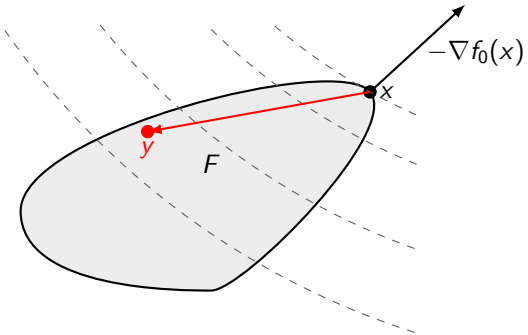


En el lenguaje de la Unidad 5: $x^\star$ es óptimo $\iff -\nabla f_0(x^\star) \in N_F(x^\star)$.

Criterio de optimalidad para f_0 diferenciable

$x \in F$ es óptimo si y solo si

$$\nabla f_0(x)^T (y - x) \geq 0 \qquad \forall y \in F$$



En el lenguaje de la Unidad 5: $x^\star$ es óptimo $\iff -\nabla f_0(x^\star) \in N_F(x^\star)$.

Condiciones KKT para f_i diferenciables

Para problemas convexos: **Condiciones KKT** (para un problema con f_i, h_i diferenciables) son:

1. **Restricciones primales:** $f_i(x) \leq 0, \quad i = 1, \ldots, m; \qquad h_i(x) = 0, \quad i = 1, \ldots, p$
2. **Restricciones duales:** $\lambda \geq 0$
3. **Holgura complementaria:** $\lambda_i f_i(x) = 0, \quad i = 1, \ldots, m$
4. **Gradiente del Lagrangiano respecto de x es nulo:**

$$\nabla f_0(x) + \sum_{i=1}^{m} \lambda_i \nabla f_i(x) + \sum_{i=1}^{p} \nu_i \nabla h_i(x) = 0$$

Si hay dualidad fuerte y x, λ, ν son óptimos, satisfacen las condiciones KKT.

Lagrangiano

La condición KKT se puede escribir usando el Lagrangiano:

Lagrangiano: $L : \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \to \mathbb{R}$, con dom $L = \mathcal{D} \times \mathbb{R}^m \times \mathbb{R}^p$,

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^{m} \lambda_i f_i(x) + \sum_{i=1}^{p} \nu_i h_i(x)$$

como

$$\begin{cases} \nabla_x L(x, \lambda, \nu) = 0, \\ \nabla_\lambda L(x, \lambda, \nu) \leq 0, \\ \nabla_\nu L(x, \lambda, \nu) = 0, \\ \lambda_i f_i(x) = 0, \quad i = 1, \ldots, m, \\ \lambda \geq 0. \end{cases}$$

Si no hay desigualdades recuperamos el TML: $\nabla L(x, \nu) = 0$.

Función dual de Lagrange

Función dual de Lagrange: $g : \mathbb{R}^m \times \mathbb{R}^p \to \mathbb{R}$,

$$g(\lambda, \nu) = \inf_{x \in \mathcal{D}} L(x, \lambda, \nu) = \inf_{x \in \mathcal{D}} \left(f_0(x) + \sum_{i=1}^{m} \lambda_i f_i(x) + \sum_{i=1}^{p} \nu_i h_i(x) \right)$$

- g es cóncava, puede ser $-\infty$ para algunos valores de λ, ν
- **Propiedad de cota inferior:** si $\lambda \geq 0$, entonces $g(\lambda, \nu) \leq p^\star$
- **Demostración:** si $\bar{x}$ es factible y $\lambda \geq 0$, entonces

$$f_0(\bar{x}) \geq L(\bar{x}, \lambda, \nu) \geq \inf_{x \in \mathcal{D}} L(x, \lambda, \nu) = g(\lambda, \nu)$$

Minimizar sobre todos los $\bar{x}$ factibles da $p^\star \geq g(\lambda, \nu)$

Problema dual de Lagrange

Problema dual (de Lagrange)

$$\begin{aligned} \text{maximizar} \quad & g(\lambda, \nu) = \inf_{x \in \mathcal{D}} L(x, \lambda, \nu) \\ \text{s. a} \quad & \lambda \geq 0 \end{aligned}$$

- Busca la mejor cota inferior de $p^\star$, obtenida a partir de la función dual de Lagrange.
- Es un problema de optimización convexa, aún si el problema **primal** original no lo es.
- El valor óptimo dual se denota $d^\star$.
- λ, ν son factibles duales si $\lambda \geq 0$, $(\lambda, \nu) \in \operatorname{dom} g$
- Frecuentemente se simplifica haciendo explícita la restricción implícita $(\lambda, \nu) \in \operatorname{dom} g$

Dualidad fuerte

Teorema de Dualidad fuerte:

Si el problema primal es convexo y se satisfacen condiciones de calificación de restricciones (por ejemplo, la condición de Slater), entonces $p^\star = d^\star$ y los problemas primal y dual son equivalentes.

Ejemplo: minimizar $f_0(x) = \frac{x^2}{2}$ sujeto a $f_1(x) = 1 - x \leq 0$.

Dualidad fuerte

Teorema de Dualidad fuerte:

Si el problema primal es convexo y se satisfacen condiciones de calificación de restricciones (por ejemplo, la condición de Slater), entonces $p^\star = d^\star$ y los problemas primal y dual son equivalentes.

Ejemplo: minimizar $f_0(x) = \frac{x^2}{2}$ sujeto a $f_1(x) = 1 - x \leq 0$.

Problema primal:

$$\begin{array}{ll} \underset{x}{\text{minimizar}} & \frac{1}{2}x^2 \\ \text{sujeto a} & x \leq 1 \end{array}$$

Problema dual:

$$\underset{\lambda \geq 0}{\text{maximizar}} \quad -\frac{1}{2}\lambda^2 - \lambda$$

Funciones convexas de ML

1. La pérdida logística:

$$\ell(z) = \log\left(1 + e^{-z}\right)$$

2. Ridge

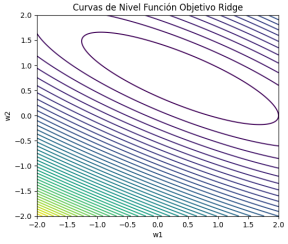
$$\min_{\theta} \|y - X\theta\|^2 + \lambda\|\theta\|^2$$

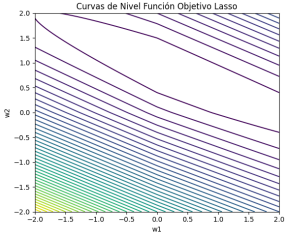
   - Estrictamente convexa si $\lambda > 0 \Rightarrow$ mínimo único.

3. Lasso

$$\min_{\theta} \|y - X\theta\|^2 + \lambda\|\theta\|_1$$

   - No diferenciable.
   - Puede no ser estrictamente convexa $\Rightarrow$ puede tener múltiples mínimos.





¿De dónde salen Ridge y Lasso?

Regularización con restricción

$$\min_{\beta} \ \|y - X\beta\|^2 \quad \text{s.a.} \quad \|\beta\|_p \leq t$$

Por dualidad de Lagrange,

$$\max_{\lambda \geq 0} \min_{\beta} \ \|y - X\beta\|^2 + \lambda(\|\beta\|_p - t)$$

Si conozco el multiplicador óptimo, el problema restringido tiene la misma solución que el problema penalizado.

$$\min_{\beta} \ \|y - X\beta\|^2 + \lambda\|\beta\|_p$$

Ridge para $p = 2$, Lasso para $p = 1$.

Ejemplo en Colab

Consideremos los problemas:

$$\textbf{Ridge:} \quad \min_{\theta} \|y - X\theta\|^2 + \lambda\|\theta\|_2^2$$

$$\textbf{Lasso:} \quad \min_{\theta} \|y - X\theta\|^2 + \lambda\|\theta\|_1$$

Preguntas:

1. Escribir la condición de optimalidad en cada caso.
2. ¿Qué cambia cuando usamos $\|\theta\|_1$?
3. ¿Por qué aparece sparsidad en Lasso?

Pista conceptual

- En Ridge la función es diferenciable.

Pensar geométricamente: bola ℓ_2 vs diamante ℓ_1.

Pista conceptual

- En Ridge la función es diferenciable.
- En Lasso la norma ℓ_1 no es diferenciable en cero.

Pensar geométricamente: bola ℓ_2 vs diamante ℓ_1.

Pista conceptual

- En Ridge la función es diferenciable.
- En Lasso la norma ℓ_1 no es diferenciable en cero.
- En problemas convexos, la condición es:

$$0 \in \partial f(\theta^\star).$$

Pensar geométricamente: bola ℓ_2 vs diamante ℓ_1.

Solución

Ridge

$$f(\theta) = \|y - X\theta\|^2 + \lambda\|\theta\|_2^2$$

Solución

Ridge

$$f(\theta) = \|y - X\theta\|^2 + \lambda\|\theta\|_2^2$$

$$\nabla f(\theta) = 2X^\top(X\theta - y) + 2\lambda\theta$$

Solución

Ridge

$$f(\theta) = \|y - X\theta\|^2 + \lambda\|\theta\|_2^2$$

$$\nabla f(\theta) = 2X^\top(X\theta - y) + 2\lambda\theta$$

Condición necesaria y suficiente (convexidad):

$$\nabla f(\theta^\star) = 0.$$

Solución

Lasso

$$f(\theta) = \|y - X\theta\|^2 + \lambda\|\theta\|_1$$

Ridge

$$f(\theta) = \|y - X\theta\|^2 + \lambda\|\theta\|_2^2$$

$$\nabla f(\theta) = 2X^\top(X\theta - y) + 2\lambda\theta$$

Condición necesaria y suficiente (convexidad):

$$\nabla f(\theta^\star) = 0.$$

$$\theta^\star = (X^\top X + \lambda I)^{-1} X^\top y.$$

Solución

Ridge

$$f(\theta) = \|y - X\theta\|^2 + \lambda\|\theta\|_2^2$$

$$\nabla f(\theta) = 2X^\top(X\theta - y) + 2\lambda\theta$$

Condición necesaria y suficiente (convexidad):

$$\nabla f(\theta^\star) = 0.$$

$$\theta^\star = (X^\top X + \lambda I)^{-1} X^\top y.$$

Lasso

$$f(\theta) = \|y - X\theta\|^2 + \lambda\|\theta\|_1$$

La norma ℓ_1 no es diferenciable.

Solución

Ridge

$$f(\theta) = \|y - X\theta\|^2 + \lambda\|\theta\|_2^2$$

$$\nabla f(\theta) = 2X^\top(X\theta - y) + 2\lambda\theta$$

Condición necesaria y suficiente (convexidad):

$$\nabla f(\theta^\star) = 0.$$

$$\theta^\star = (X^\top X + \lambda I)^{-1} X^\top y.$$

Lasso

$$f(\theta) = \|y - X\theta\|^2 + \lambda\|\theta\|_1$$

La norma ℓ_1 no es diferenciable.
Condición de optimalidad:

$$0 \in 2X^\top(X\theta - y) + \lambda\partial\|\theta\|_1.$$

Solución

Ridge

$$f(\theta) = \|y - X\theta\|^2 + \lambda\|\theta\|_2^2$$

$$\nabla f(\theta) = 2X^\top(X\theta - y) + 2\lambda\theta$$

Condición necesaria y suficiente (convexidad):

$$\nabla f(\theta^\star) = 0.$$

$$\theta^\star = (X^\top X + \lambda I)^{-1} X^\top y.$$

Lasso

$$f(\theta) = \|y - X\theta\|^2 + \lambda\|\theta\|_1$$

La norma ℓ_1 no es diferenciable.
Condición de optimalidad:

$$0 \in 2X^\top(X\theta - y) + \lambda\partial\|\theta\|_1.$$

En coordenadas:

$$\partial|\theta_i| = \begin{cases} 1 & \theta_i > 0 \\ -1 & \theta_i < 0 \\ [-1, 1] & \theta_i = 0 \end{cases}$$

$\boxed{\theta_i^* \approx \mathcal{S}_\lambda(z_i) = \text{sign}(z_i) \cdot \text{máx}(|z_i| - \lambda,\ 0)}$ donde $z = X^\top y$ son los coeficientes OLS.

Soft thresholding

Si $X^\top X = I$, LASSO se desacopla en p problemas:

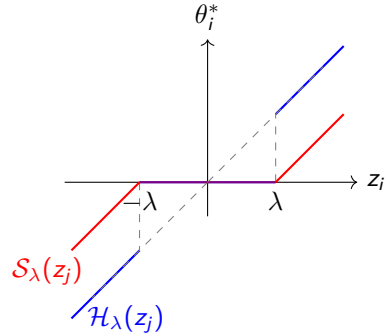
$$\min_{\theta_i} \frac{1}{2}(z_i - \theta_i)^2 + \lambda|\theta_i|$$

donde $z_i = (X^\top y)_i$ son los coeficientes OLS.

$$\boxed{\theta_i^* = \mathcal{S}_\lambda(z_i) = \text{sign}(z_i) \cdot \text{máx}(|z_i| - \lambda,\ 0)}$$

Si $|z_j| \leq \lambda \rightarrow$ cero exacto ("esparcidad").
Si $|z_j| > \lambda \rightarrow$ se encoge en λ hacia cero.

Se obtiene de $0 \in \theta_i - z_i + \lambda\,\partial|\theta_i|$ (U6). Lo retomamos con los métodos no diferenciables (U10).



	Hard	Soft
Coef. pequeños	los anula	los anula
Coef. grandes	los deja igual	los encoge en λ
Diferenciabilidad	discontinuo	continuo
Origen	variable selection	LASSO

Resumen

- **Convexidad**: local = global; el epígrafo es convexo.
- **Optimalidad sin restricciones**: suave $\Rightarrow \nabla f = 0$; no suave $\Rightarrow 0 \in \partial f$.
- **Optimalidad con restricciones**: $\nabla f_0(x)^\top (y - x) \geq 0 \ \forall y \in F$; en general $\Rightarrow$ sistema KKT.
- **Dualidad de Lagrange**: el problema dual siempre es convexo; dualidad fuerte ($p^\star = d^\star$) bajo condiciones de regularidad.
- **Regularización**: penalización $\Leftrightarrow$ restricción vía multiplicador de Lagrange; Ridge (ℓ_2) y Lasso (ℓ_1).

Conexión con la materia

Las herramientas de U1–U6 y U9 alcanzan para analizar los modelos lineales regularizados. En la próxima clase: PCA, clustering y SVM (donde reaparecen la separación de la U7 y la dualidad de la U9).

Bibliografía

- Boyd & Vandenberghe — Convex Optimization.
- Nocedal & Wright — Numerical Optimization.
- Hastie, Tibshirani, Friedman — ESL.