Optimización en Ciencia de Datos

Clase 2: reducción de dimensionalidad, clustering y clasificación

Pablo A. Lotito Victoria Orlando

Modelización Matemática
Facultad de Ciencias Exactas – UNCPBA

2.º cuatrimestre 2026









Segmentación y Clasificación en ML

Tabla de Contenidos

- Reducción de dimensionalidad
- Aprendizaje no supervisado
  - Clustering geométrico
  - Clustering espectral
- Aprendizaje supervisado
  - Regresión lineal
  - Regresión logística
  - SVM

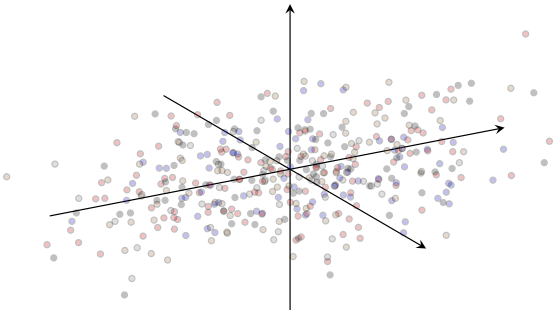
Puente con lo que ya vimos en Modelización

Lo que ya vimos	Unidad	Dónde aparece hoy
Matrices semidefinidas, cono S_+^n	U1	Covarianza muestral y laplaciano de un grafo
Nota sobre valores singulares	U3	PCA y descomposición SVD
Convexidad y operaciones que la preservan	U2–U3	Pérdida logística
Condición de primer orden, descenso	U4	Ecuaciones normales; k-means como descenso por bloques
Hiperplanos de separación	U7	SVM: el hiperplano de margen máximo
Lagrangiano, KKT y dualidad	U9	PCA como problema con restricción; dual de la SVM

Lo que muestra esta clase

Varios problemas centrales del aprendizaje no son convexos (PCA, k-means), pero se resuelven bien gracias a la estructura que ya estudiamos.

Varianza muestral y motivación de PCA



¿Qué dirección captura mejor la variabilidad de los datos?

Para un conjunto de datos $\{x_i\}_{i=1}^n \subset \mathbb{R}^d$, centrados:

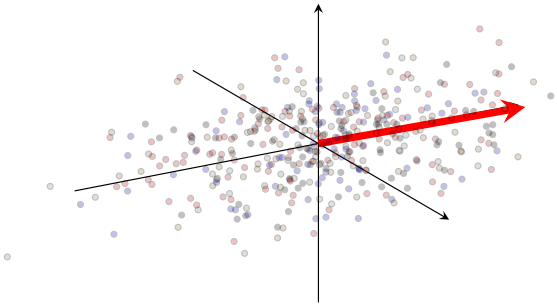
$$\mathrm{Var}(u^\top x) = u^\top S u\,, \quad \text{con} \quad S = \frac{1}{n}\sum_{i=1}^{n} x_i x_i^\top$$

Buscamos entonces

$$u^* = \underset{\|u\|=1}{\arg\max}\ u^\top S u$$

Geométricamente, u^* apunta en la dirección más *"alargada"* de la nube.

Varianza muestral y motivación de PCA



¿Qué dirección captura mejor la variabilidad de los datos?

Para un conjunto de datos $\{x_i\}_{i=1}^n \subset \mathbb{R}^d$, centrados:

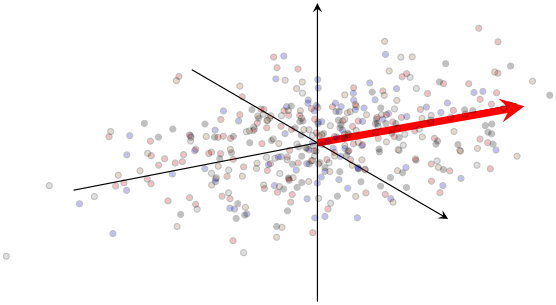
$$\mathrm{Var}(u^\top x) = u^\top S u\,, \quad \text{con} \quad S = \frac{1}{n}\sum_{i=1}^{n} x_i x_i^\top$$

Buscamos entonces

$$u^* = \underset{\|u\|=1}{\arg\max}\ u^\top S u$$

Geométricamente, u^* apunta en la dirección más *"alargada"* de la nube.

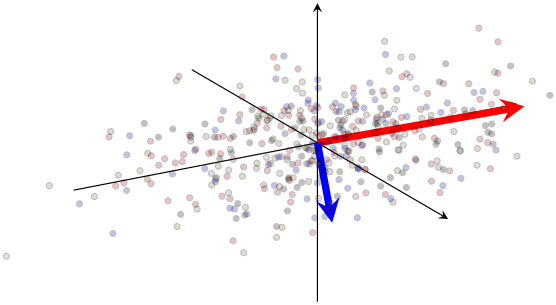
Varianza muestral y motivación de PCA



Y qué pasa con las variaciones que no ve u ?
Podemos buscar ahora $v \perp u$ que maximice la varianza proyectada sobre v

$$\max_{\substack{v^\top u = 0 \\ \|v\| = 1}} v^\top S v$$

Varianza muestral y motivación de PCA



Y qué pasa con las variaciones que no ve u ?
Podemos buscar ahora $v \perp u$ que maximice la varianza proyectada sobre v

$$\max_{\substack{v^\top u = 0 \\ \|v\| = 1}} v^\top S v$$

Construcción PCA

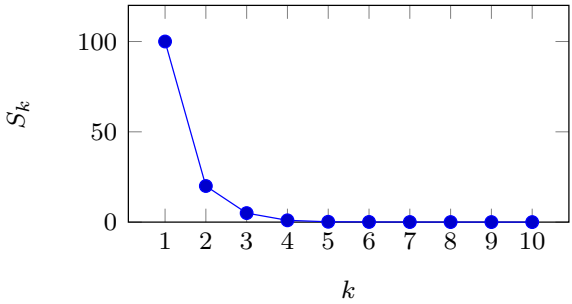
Dado un conjunto de datos $X \in \mathbb{R}^{n \times d}$,

$$u_1^* = \underset{\|u_1\|=1}{\arg\max}\, u_1^\top S u_1$$

$$u_2^* = \underset{\|u_2\|=1,\, u_2^\top u_1 = 0}{\arg\max}\, u_2^\top S u_2$$

$$\vdots$$

$$u_k^* = \underset{\|u_k\|=1,\, u_k^\top u_j = 0,\, j<k}{\arg\max}\, u_k^\top S u_k$$



- Selección de variables más relevantes: quedarse solo con los m componentes principales.
- Reducción de dimensionalidad para visualización o cálculo.
- Representación de datos en una base nueva donde las variables son no correlacionadas y la variación es máxima en las primeras direcciones.

PCA con multiplicadores de Lagrange

$$\max_{u \in \mathbb{R}^d} \; u^\top S u \quad \text{s.a.} \quad h(u) = u^\top u - 1 = 0$$

Lagrangiano:

$$L(u, \nu) = u^\top S u - \nu \, (u^\top u - 1)$$

Condición de primer orden:

$$\nabla_u L = 2Su - 2\nu u = 0 \implies Su = \nu u.$$

PCA con multiplicadores de Lagrange

$$\max_{u \in \mathbb{R}^d} \; u^\top S u \quad \text{s.a.} \quad h(u) = u^\top u - 1 = 0$$

Lagrangiano:

$$L(u, \nu) = u^\top S u - \nu \, (u^\top u - 1)$$

Condición de primer orden:

$$\nabla_u L = 2Su - 2\nu u = 0 \implies Su = \nu u.$$

Los puntos críticos son los **autovectores** de S y el valor es $u^\top S u = \nu$: el máximo se alcanza en $\lambda_{\text{máx}}(S)$.

PCA con multiplicadores de Lagrange

$$\max_{u \in \mathbb{R}^d} \; u^\top S u \quad \text{s.a.} \quad h(u) = u^\top u - 1 = 0$$

Lagrangiano:

$$L(u, \nu) = u^\top S u - \nu\,(u^\top u - 1)$$

Condición de primer orden:

$$\nabla_u L = 2Su - 2\nu u = 0 \implies Su = \nu u.$$

Los puntos críticos son los **autovectores** de S y el valor es $u^\top S u = \nu$: el máximo se alcanza en $\lambda_{\text{máx}}(S)$.

Observaciones

- *No* es un problema convexo: se maximiza una función convexa sobre la esfera, que no es un conjunto convexo.
- Las condiciones de la U9 son sólo **necesarias** acá (la restricción es regular: $\nabla h(u) = 2u \neq 0$).
- Aun así la solución global se conoce: es un problema no convexo con estructura.

Escalado y PCA

Importante

Siempre escalar **antes** de aplicar PCA, salvo que todas las variables estén en la misma unidad.

Preproceso estándar

$$x'_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

Deja cada variable con $\mu = 0$ y $\sigma^2 = 1$. Sobre X' se calcula $S = \frac{1}{n} {X'}^\top X'$.

Pipeline completo:

1. **Centrar y escalar** cada variable.

$$x' = \frac{x - \mu}{\sigma}$$

2. **Calcular covarianza** $S = \frac{1}{n} {X'}^\top X'$
3. **Eigen-descomposición** $S = U \Lambda U^\top$
4. **Proyectar** $z_i = U_k^\top x'_i \in \mathbb{R}^k$

Interpretación geométrica

La nube elipsoidal se **rota** para alinear sus ejes principales con las nuevas coordenadas $z_1, z_2, \ldots$

Los ejes originales $x_1, \ldots, x_d$ **no cambian**: PCA elige una base nueva rotada respecto a ellos.

Descomposición espectral y valores singulares

Sea $S \in \mathbb{R}^{d \times d}$ **simétrica semidefinida positiva** ($S \succeq 0$).

Descomposición espectral

$$S = Q \Lambda Q^\top, \quad Q = [q_1, \ldots, q_d] \text{ ortogonal}, \quad \Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_d), \ \lambda_i \geq 0.$$

Descomposición espectral y valores singulares

Sea $S \in \mathbb{R}^{d\times d}$ **simétrica semidefinida positiva** ($S \succeq 0$).

Descomposición espectral

$$S = Q\Lambda Q^\top, \quad Q = [q_1, \ldots, q_d] \text{ ortogonal}, \quad \Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_d),\ \lambda_i \geq 0.$$

- Problema de Rayleigh:

$$\max_{\|u\|=1} u^\top S u \;=\; \lambda_{\max}(S), \quad \text{con máximo en } u = q_1.$$

- Si $X \in \mathbb{R}^{n\times d}$ son los datos centrados por filas, $S = \frac{1}{n} X^\top X$.

Descomposición espectral y valores singulares

Visto en U3 · Nota sobre valores singulares

Sea $S \in \mathbb{R}^{d\times d}$ **simétrica semidefinida positiva** ($S \succeq 0$).

Descomposición espectral

$$S = Q\Lambda Q^\top, \quad Q = [q_1, \ldots, q_d] \text{ ortogonal}, \quad \Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_d),\ \lambda_i \geq 0.$$

- Problema de Rayleigh:

$$\max_{\|u\|=1} u^\top S u \;=\; \lambda_{\max}(S), \quad \text{con máximo en } u = q_1.$$

- Si $X \in \mathbb{R}^{n\times d}$ son los datos centrados por filas, $S = \frac{1}{n} X^\top X$.

Conexión con SVD

SVD de X: $X = U\Sigma V^\top$, $\Sigma = \operatorname{diag}(\sigma_1, \ldots, \sigma_r)$. Entonces $X^\top X = V\Sigma^2 V^\top$, luego

$$S = V\left(\tfrac{1}{n}\Sigma^2\right)V^\top, \quad q_i = v_i,\ \lambda_i = \tfrac{1}{n}\sigma_i^2.$$

PCA como reducción de dimensionalidad

Ordenamos autovalores de S (o valores singulares de X):

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_d \geq 0.$$

Subespacio de dimensión k

Sea $Q_k = [q_1, \ldots, q_k] \in \mathbb{R}^{d \times k}$. La proyección de un dato $x \in \mathbb{R}^d$ en las k primeras componentes es

$$z = Q_k^\top x \in \mathbb{R}^k.$$

PCA como reducción de dimensionalidad

Ordenamos autovalores de S (o valores singulares de X):

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_d \geq 0.$$

Subespacio de dimensión k

Sea $Q_k = [q_1, \ldots, q_k] \in \mathbb{R}^{d \times k}$. La proyección de un dato $x \in \mathbb{R}^d$ en las k primeras componentes es

$$z = Q_k^\top x \in \mathbb{R}^k.$$

- **Reconstrucción** aproximada: $\hat{x} = Q_k z = Q_k Q_k^\top x$.
- El subespacio generado por $q_1, \ldots, q_k$ *maximiza la varianza explicada* y *minimiza el error cuadrático de reconstrucción* entre todos los subespacios de dimensión k.
- En la práctica: usar z como representación compacta para visualización, clustering o clasificación.

Clustering

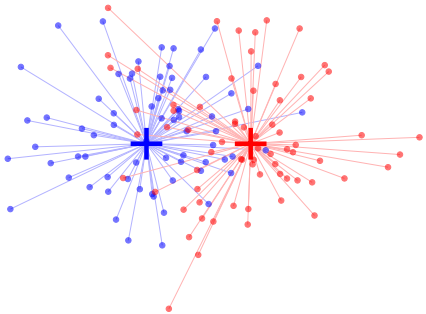
Supongamos que tenemos una nube de puntos en $\mathbb{R}^d$ y queremos encontrar una partición de los puntos en 2 grupos, de modo que los puntos de un grupo estén cerca entre sí pero lejos del otro grupo.



Clustering

Supongamos que tenemos una nube de puntos en $\mathbb{R}^d$ y queremos encontrar una partición de los puntos en 2 grupos, de modo que los puntos de un grupo estén cerca entre sí pero lejos del otro grupo.

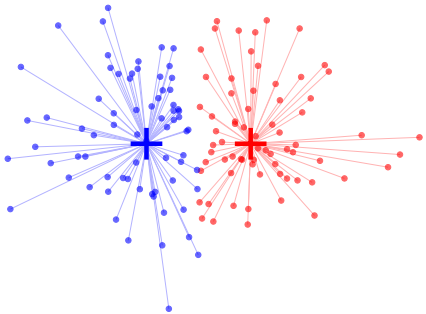
Problema: Hallar μ_j tal que $x_i \in C_j$ si $d(x_i, \mu_j) < d(x_i, \mu_k)$ para todo $k \neq j$. Y además, cada μ_j es le baricentro de la clase C_j.



Clustering

Supongamos que tenemos una nube de puntos en $\mathbb{R}^d$ y queremos encontrar una partición de los puntos en 2 grupos, de modo que los puntos de un grupo estén cerca entre sí pero lejos del otro grupo.

Problema: Hallar μ_j tal que $x_i \in C_j$ si $d(x_i, \mu_j) < d(x_i, \mu_k)$ para todo $k \neq j$. Y además, cada μ_j es le baricentro de la clase C_j.



Clustering geométrico: K-means

Problema

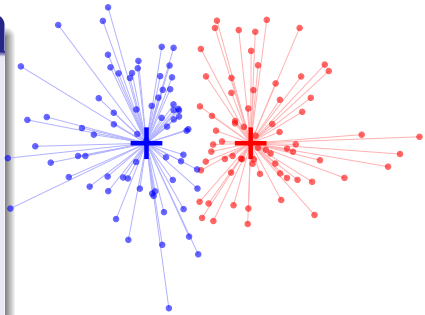
Dado un conjunto de datos $\{x_i\}_{i=1}^n \subset \mathbb{R}^d$, K-means busca una partición $\{C_1, \ldots, C_K\}$ que minimice

$$\sum_{k=1}^{K} \sum_{x_i \in C_k} \|x_i - \mu_k\|_2^2,$$

donde

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

es el centroide del cluster C_k.



Clustering geométrico: K-means

Problema

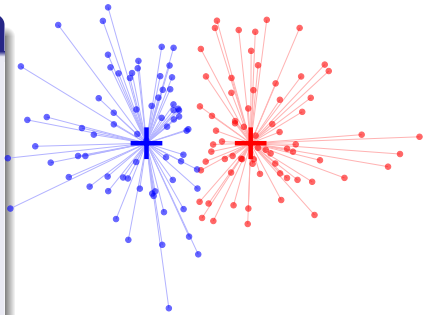
Dado un conjunto de datos $\{x_i\}_{i=1}^n \subset \mathbb{R}^d$, K-means busca una partición $\{C_1, \ldots, C_K\}$ que minimice

$$\sum_{k=1}^{K} \sum_{x_i \in C_k} \|x_i - \mu_k\|_2^2,$$

donde

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

es el centroide del cluster C_k.

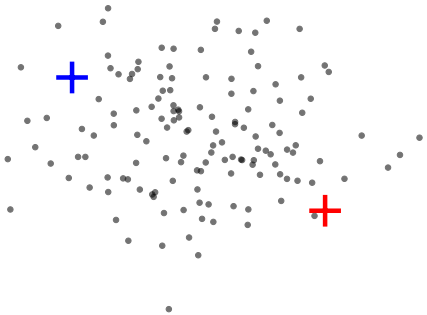


¿Cuál es la variable de optimización ?

Clustering geométrico: K-means

Algoritmo (método de Lloyd)

- **Paso 1 (asignación):** asignar cada punto al centroide más cercano.
- **Paso 2 (actualización):** recomputar centroides como medias de los puntos asignados.
- Repetir hasta convergencia (sin cambios de asignación o cambio pequeño en el objetivo).
- Siempre termina en un mínimo local.

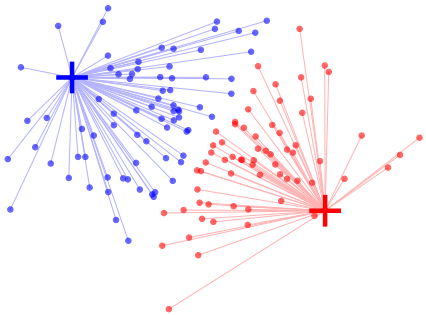


Lectura desde la U4: es un descenso por bloques. Con las asignaciones fijas, la condición de primer orden $\nabla_{\mu_k} J = 0$ da $\mu_k =$ media del cluster; con los centroides fijos, asignar al más cercano minimiza J. El objetivo nunca crece.

Clustering geométrico: K-means

Algoritmo (método de Lloyd)

- **Paso 1 (asignación):** asignar cada punto al centroide más cercano.
- **Paso 2 (actualización):** recomputar centroides como medias de los puntos asignados.
- Repetir hasta convergencia (sin cambios de asignación o cambio pequeño en el objetivo).
- Siempre termina en un mínimo local.

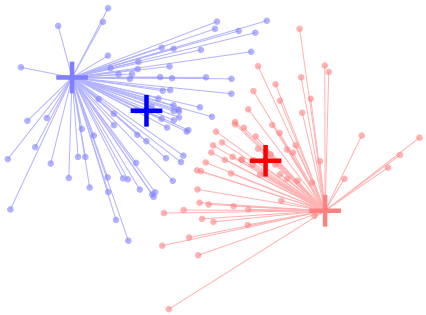


Lectura desde la U4: es un descenso por bloques. Con las asignaciones fijas, la condición de primer orden $\nabla_{\mu_k} J = 0$ da $\mu_k =$ media del cluster; con los centroides fijos, asignar al más cercano minimiza J. El objetivo nunca crece.

Clustering geométrico: K-means

Algoritmo (método de Lloyd)

- **Paso 1 (asignación):** asignar cada punto al centroide más cercano.
- **Paso 2 (actualización):** recomputar centroides como medias de los puntos asignados.
- Repetir hasta convergencia (sin cambios de asignación o cambio pequeño en el objetivo).
- Siempre termina en un mínimo local.



Lectura desde la U4: es un descenso por bloques. Con las asignaciones fijas, la condición de primer orden $\nabla_{\mu_k} J = 0$ da $\mu_k =$ media del cluster; con los centroides fijos, asignar al más cercano minimiza J. El objetivo nunca crece.

Clustering espectral

Ventajas K-means

Favorece clusters:

- compactos,
- convexos,
- separados en distancia euclídea.

Limitaciones del Clustering geométrico

- Sensible a la inicialización.
- Supone clusters aproximadamente esféricos.
- Falla en estructuras no convexas.

Clustering espectral

Ventajas K-means

Favorece clusters:

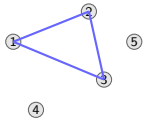
- compactos,
- convexos,
- separados en distancia euclídea.

Limitaciones del Clustering geométrico

- Sensible a la inicialización.
- Supone clusters aproximadamente esféricos.
- Falla en estructuras no convexas.

Idea:

Cambiar la métrica (o la topología) usando un matriz de similaridad. Los vecinos se definen explícitamente por una matriz de adyacencia A.

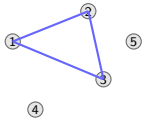


$$A = \begin{pmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 & 0 \end{pmatrix}$$

Grafos y matrices

Grafo $G = (V, E)$

- V es el conjunto de nodos.
- E es el conjunto de aristas.
- A es la matriz de adyacencia (nodo-nodo).
- B es la matriz de incidencia (arco-nodo).
- D es la matriz (diagonal) de grados.
- L es el laplaciano.



$$A = \begin{pmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 & 0 \end{pmatrix}$$

$$A_{ij} = \begin{cases} 1 & \text{si } (i,j) \in E, \\ 0 & \text{si no.} \end{cases} \qquad B_{ek} = \begin{cases} 1 & \text{si } k = e^+, \\ -1 & \text{si } k = e^-, \\ 0 & \text{si no.} \end{cases} \qquad L = B^\top B = D - A$$

De la similaridad a la matriz de incidencia

Similaridad

- Asocia a cada para x_i, x_j una medida de similaridad $w_{ij} \geq 0$.
- Usando un kernel $w : \mathbb{R}^d \times \mathbb{R}^d \to [0, 1]$

$$w_{ij} = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right).$$

- w_{ij} grande $\Rightarrow$ x_i, x_j *similares*.
- $w_{ij} \approx 0$ si están lejos.

Matriz de incidencia ponderada B

$B \in \mathbb{R}^{n \times |E|}$, una columna por arista $e = (i, j)$:

$$B_{ek} = \begin{cases} -\sqrt{w_{ij}} & k = i, \\ \sqrt{w_{ij}} & k = j, \\ 0 & \text{si no.} \end{cases}$$

Umbral de similaridad

Se puede usar un umbral para simplificar o binarizar la matriz de incidencia.

El grafo kNN

Otra forma de construir el grafo es usando el

Algoritmo kNN

- Para cada nodo i, conectar con sus k vecinos más cercanos.
- Distancia típica: euclidiana sobre x_i escalados o similaridad.
- Se puede forzar la simetría tomando unión o intersección de vecinos.

Grafo completo ($n = 6,\ |E| = 15$)



El grafo kNN

Otra forma de construir el grafo es usando el

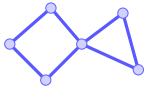
Algoritmo kNN

- Para cada nodo i, conectar con sus k vecinos más cercanos.
- Distancia típica: euclidiana sobre x_i escalados o similaridad.
- Se puede forzar la simetría tomando unión o intersección de vecinos.

Grafo completo ($n = 6$, $|E| = 15$)



kNN (k=2, simetrizado, $|E|$=7)



El grafo kNN

Otra forma de construir el grafo es usando el

Algoritmo kNN

- Para cada nodo i, conectar con sus k vecinos más cercanos.
- Distancia típica: euclidiana sobre x_i escalados o similaridad.
- Se puede forzar la simetría tomando unión o intersección de vecinos.

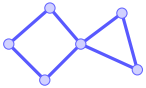
Elección de k

- k muy chico: grafo desconectado.
- k muy grande: se pierde estructura local.

Grafo completo ($n = 6$, $|E| = 15$)



kNN (k=2, simetrizado, $|E|$=7)



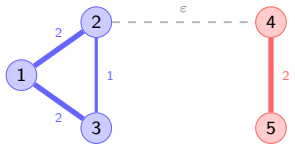
Laplacianos

Laplaciano

- $L = D - A$.
- Propiedad clave:
  $f^\top L f = \frac{1}{2} \sum_{i,j} A_{ij}(f_i - f_j)^2 \geq 0$.
- Entonces L es semidefinida positiva.

Laplacianos normalizados

- $L_{sym} = I - D^{-1/2} A D^{-1/2}$.
- $L_{rw} = I - D^{-1} A$.
- Ayudan cuando hay heterogeneidad de grados en el grafo.



$$f = (\underbrace{1, 1, 1}_{\text{azul}}, \underbrace{-1, -1}_{\text{rojo}})^\top$$

$$f^\top L f = \varepsilon(1 - (-1))^2 = 4\varepsilon \approx 0$$

$\Rightarrow$ corte de bajo costo

Clustering espectral

El **Laplaciano** es el objeto central del clustering espectral.

1. **Mide suavidad de funciones sobre el grafo**

$$f^\top L f = \sum_{(i,j)\in E} w_{ij}(f_i - f_j)^2$$

Si f es un indicador de cluster ($f_i = +1$ o -1), esta cantidad es exactamente el *costo del corte*: suma de los pesos de las aristas que cruzan la frontera entre clusters. Minimizar $f^\top L f$ equivale a buscar un corte de bajo costo.

2. **Su espectro revela la estructura del grafo**
   - Conexión: Conexo si el autovector asociado a $\lambda_0 = 0$ es constante.
   - Separación de clusters: El autovector asociado al siguiente autovalor (λ_1) es el *vector de Fiedler* y separa el grafo en dos partes según el signo de sus componentes.
   - **Los k primeros autovectores** dan un *embedding* de los nodos en $\mathbb{R}^k$ que captura la geometría del grafo.

Clustering espectral: intuición

Buscar clusters equivale a cortar pocas aristas entre grupos densos.

$$\text{MinCut} \;\Rightarrow\; \text{particiones con baja conexión cruzada.}$$

La formulación exacta es combinatoria (NP-hard); se usa relajación convexa/espectral.

Relajación espectral

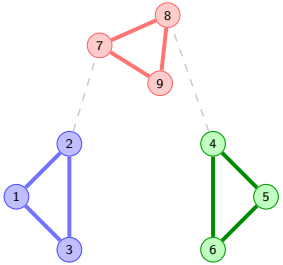
$$\min_{U \in \mathbb{R}^{n \times k}} \operatorname{Tr}(U^\top L U) \quad \text{s.a.} \quad U^\top U = I$$

Solución: k primeros autovectores de L

Sobre ese embedding se corre **k-means** para recuperar la partición discreta.

Ejemplo: embedding espectral con $k = 3$

Grafo con 3 clusters ($n = 9$ nodos):



Autovectores 2do y 3ro de L (los que discriminan):

$$U = [u_2, u_3] \approx \begin{pmatrix} a & 0 \\ a & 0 \\ a & 0 \\ 0 & b \\ 0 & b \\ 0 & b \\ -a & -b \\ -a & -b \\ -a & -b \end{pmatrix}$$

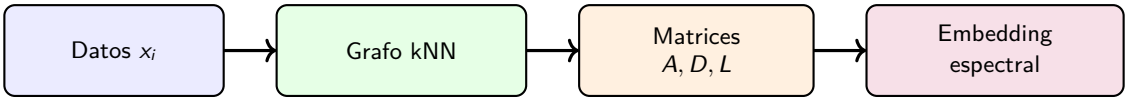
($u_1 = c \cdot \mathbf{1}$: constante, no discrimina)

Embedding $\tilde{x}_i = \text{fila}_i(U) \in \mathbb{R}^2$:

- Nodos 1,2,3: $(a,\ 0)$
- Nodos 4,5,6: $(0,\ b)$
- Nodos 7,8,9: $(-a,\ -b)$

K-means en $\mathbb{R}^2$ separa trivialmente los 3 vértices

Resumen clustering espectral



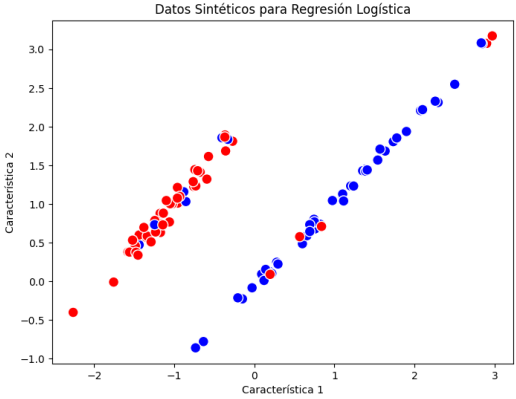
Cada bloque agrega estructura y reduce ruido para separar mejor los segmentos.

Ejemplo en Google Colab

Ejemplo resuelto: Abrir notebook en Google Colab

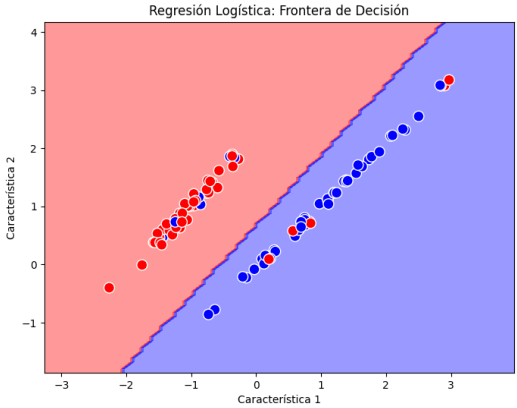
Aprendizaje supervisado

- Aprendizaje supervisado: aprendemos un modelo f a partir de un dataset (x_i, y_i).
- El modelo f es una función que mapea x_i a y_i.
- El dataset es un conjunto de pares (x_i, y_i).



Aprendizaje supervisado

- Aprendizaje supervisado: aprendemos un modelo f a partir de un dataset (x_i, y_i).
- El modelo f es una función que mapea x_i a y_i.
- El dataset es un conjunto de pares (x_i, y_i).

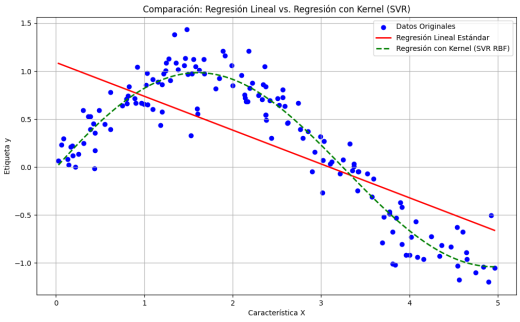


Regresión lineal

- El dataset es un conjunto de pares (x_i, y_i), $y_i \in \mathbb{R}$.
- Se busca un modelo $y = f(x, \theta)$ con f lineal que mejor aproxime los datos.

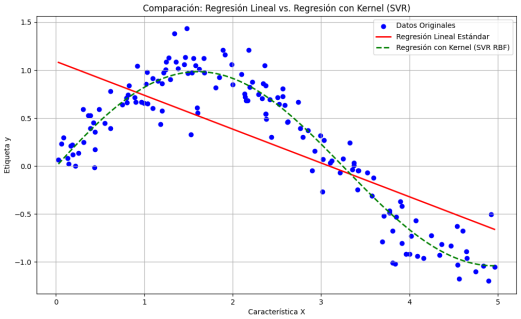
Formulación

$$\min_{\theta \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^{n} \Big(y_i - f(x_i, \theta) \Big)^2$$



Regresión lineal

- El dataset es un conjunto de pares (x_i, y_i), $y_i \in \mathbb{R}$.
- Se busca un modelo $y = f(x, \theta)$ con f lineal que mejor aproxime los datos.



Formulación

$$\min_{\theta \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^{n} \Big(y_i - f(\phi(x_i), \theta) \Big)^2 + \lambda R(\theta)$$

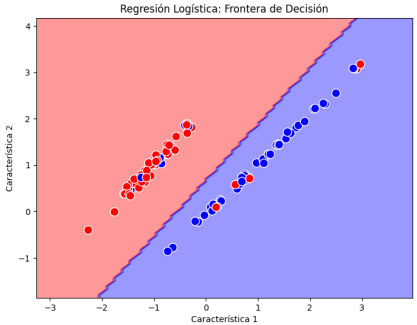
- $\phi(x_i)$ kernel.
- $R(\theta)$ regularización.

Regresión logística

- El dataset es un conjunto de pares (x_i, y_i), $y_i \in \{0, 1\}$.
- Se busca un modelo para $P(Y = 1|X = x) = \frac{\exp(\theta^\top x)}{1+\exp(\theta^\top x)}$
- Se maximiza log likelihood.

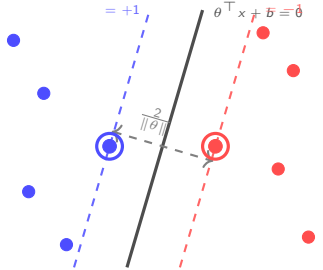
$$\min_{\theta \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^{n} \Big[- y_i \log p_i - (1 - y_i) \log(1 - p_i) \Big] + \frac{\lambda}{2} \|\theta\|_2^2,$$

$$p_i = \frac{\exp(x_i^\top \theta)}{1 + \exp(x_i^\top \theta)}.$$



SVM — margen óptimo

- Dataset $\{(x_i, y_i)\}$, $y_i \in \{-1, +1\}$.
- Se busca el hiperplano $\theta^\top x + b = 0$ que **maximiza el margen** entre clases.
- El margen es $\frac{2}{\|\theta\|}$; maximizarlo equivale a minimizar $\|\theta\|$.



Problema primal (separable)

$$\min_{\theta, b} \ \frac{1}{2}\|\theta\|_2^2 \quad \text{s.a.} \quad y_i(\theta^\top x_i + b) \ \geq \ 1$$

Versión soft-margin ($C > 0$)

$$\min_{\theta, b, \xi} \ \frac{1}{2}\|\theta\|_2^2 + C \sum_i \xi_i \quad \text{s.a.} \quad y_i(\theta^\top x_i + b) \geq 1 - \xi_i, \ \xi_i \geq 0$$

SVM: problema dual y vectores soporte

Con multiplicadores $\alpha_i \geq 0$:

$$L(\theta, b, \alpha) = \tfrac{1}{2}\|\theta\|_2^2 - \sum_{i=1}^{n} \alpha_i \big[y_i(\theta^\top x_i + b) - 1 \big]$$

Estacionariedad:

$$\nabla_\theta L = 0 \Rightarrow \theta = \sum_i \alpha_i y_i x_i, \qquad \partial_b L = 0 \Rightarrow \sum_i \alpha_i y_i = 0.$$

SVM: problema dual y vectores soporte

Con multiplicadores $\alpha_i \geq 0$:

$$L(\theta, b, \alpha) = \tfrac{1}{2}\|\theta\|_2^2 - \sum_{i=1}^{n} \alpha_i \big[y_i(\theta^\top x_i + b) - 1\big]$$

Estacionariedad:

$$\nabla_\theta L = 0 \Rightarrow \theta = \sum_i \alpha_i y_i x_i, \qquad \partial_b L = 0 \Rightarrow \sum_i \alpha_i y_i = 0.$$

Problema dual

$$\max_{\alpha \geq 0} \sum_i \alpha_i - \tfrac{1}{2} \sum_{i,j} \alpha_i \alpha_j \, y_i y_j \, x_i^\top x_j \quad \text{s.a.} \quad \sum_i \alpha_i y_i = 0$$

SVM: problema dual y vectores soporte

Con multiplicadores $\alpha_i \geq 0$:

$$L(\theta, b, \alpha) = \tfrac{1}{2}\|\theta\|_2^2 - \sum_{i=1}^{n} \alpha_i \big[y_i(\theta^\top x_i + b) - 1\big]$$

Estacionariedad:

$$\nabla_\theta L = 0 \Rightarrow \theta = \sum_i \alpha_i y_i x_i, \qquad \partial_b L = 0 \Rightarrow \sum_i \alpha_i y_i = 0.$$

Problema dual

$$\max_{\alpha \geq 0} \sum_i \alpha_i - \tfrac{1}{2} \sum_{i,j} \alpha_i \alpha_j \, y_i y_j \, x_i^\top x_j \quad \text{s.a.} \quad \sum_i \alpha_i y_i = 0$$

- **Holgura complementaria:** $\alpha_i \big[y_i(\theta^\top x_i + b) - 1\big] = 0$. Sólo los puntos sobre el margen tienen $\alpha_i > 0$: son los **vectores soporte**.
- **Dualidad fuerte:** las restricciones son afines, así que alcanza con que el problema sea factible (datos separables).
- El dual sólo usa productos internos $x_i^\top x_j$: de ahí sale el *kernel trick*.
- **Conexión con la U7:** el margen $2/\|\theta\|$ es la distancia entre las cápsulas convexas de ambas clases.

Regresión Logística vs SVM (Margen Óptimo)

Regresión Logística

- Modelo:

$$p(y = 1|x) = \sigma(w^\top x + b)$$

- Función objetivo:

$$\text{mín} \sum_{i=1}^{n} \log\left(1 + e^{-y_i(w^\top x_i + b)}\right)$$

- Usa **todos los datos**
- Salida: **probabilidad**
- Modelo estadístico, maximiza verosimilitud
- Sensible a outliers

SVM (Margen Óptimo)

- Modelo:

$$f(x) = w^\top x + b$$

- Función objetivo:

$$\text{mín}\ \frac{1}{2}\|w\|^2 + C \sum \text{máx}(0,\ 1 - y_i f(x_i))$$

- Usa solo **vectores soporte**
- Salida: **score / margen**
- Modelo geométrico, maximiza el margen
- Robusto a outliers

Kernels y el espacio $\mathcal{H}$

Kernel

$k : \mathbb{R}^d \times \mathbb{R}^d \to \mathbb{R}$ simétrico tal que, para cualquier conjunto de puntos, la matriz de Gram $K_{ij} = k(x_i, x_j)$ es semidefinida positiva: $K \in S_+^n$.

Espacio $\mathcal{H}$ asociado (RKHS)

Funciones $f = \sum_j c_j \, k(z_j, \cdot)$ (y sus límites), con

$$\langle k(x, \cdot), k(z, \cdot) \rangle_{\mathcal{H}} = k(x, z).$$

Propiedad reproductora: evaluar es un producto interno,

$$f(x) = \langle f, \, k(x, \cdot) \rangle_{\mathcal{H}}.$$

Kernels y el espacio $\mathcal{H}$

Kernel

$k : \mathbb{R}^d \times \mathbb{R}^d \to \mathbb{R}$ simétrico tal que, para cualquier conjunto de puntos, la matriz de Gram $K_{ij} = k(x_i, x_j)$ es semidefinida positiva: $K \in S^n_+$.

Espacio $\mathcal{H}$ asociado (RKHS)

Funciones $f = \sum_j c_j\, k(z_j, \cdot)$ (y sus límites), con

$$\langle k(x,\cdot), k(z,\cdot)\rangle_{\mathcal{H}} = k(x,z).$$

Propiedad reproductora: evaluar es un producto interno,

$$f(x) = \langle f,\ k(x,\cdot)\rangle_{\mathcal{H}}.$$

Ejemplo: kernel lineal $k(x,z) = x^\top z$.

- $\mathcal{H} = \{f(x) = w^\top x\}, \quad \|f\|_{\mathcal{H}} = \|w\|_2$.
- El teorema que sigue dice: $w = \sum_i \alpha_i x_i$.

Kernels y el espacio $\mathcal{H}$

Kernel

$k : \mathbb{R}^d \times \mathbb{R}^d \to \mathbb{R}$ simétrico tal que, para cualquier conjunto de puntos, la matriz de Gram $K_{ij} = k(x_i, x_j)$ es semidefinida positiva: $K \in S^n_+$.

Espacio $\mathcal{H}$ asociado (RKHS)

Funciones $f = \sum_j c_j\, k(z_j, \cdot)$ (y sus límites), con

$$\langle k(x,\cdot), k(z,\cdot)\rangle_{\mathcal{H}} = k(x,z).$$

Propiedad reproductora: evaluar es un producto interno,

$$f(x) = \langle f,\, k(x,\cdot)\rangle_{\mathcal{H}}.$$

Ejemplo: kernel lineal $k(x,z) = x^\top z$.

- $\mathcal{H} = \{f(x) = w^\top x\}, \quad \|f\|_{\mathcal{H}} = \|w\|_2$.
- El teorema que sigue dice: $w = \sum_i \alpha_i x_i$.

Ya lo vimos dos veces

- Dual de la SVM: $\theta = \sum_i \alpha_i y_i x_i$.
- Ridge: $\theta^\star = (X^\top X + \lambda I)^{-1} X^\top y = X^\top \alpha$, con $\alpha = (XX^\top + \lambda I)^{-1} y$.

En ambos casos la solución es una combinación de los datos.

Teorema del representante

Teorema (Kimeldorf y Wahba, 1971; Schölkopf, Herbrich y Smola, 2001)

Sea L una pérdida cualquiera y $\lambda > 0$. Todo minimizador de

$$\min_{f \in \mathcal{H}} \sum_{i=1}^{n} L\big(y_i, f(x_i)\big) + \lambda \|f\|_{\mathcal{H}}^2$$

es de la forma $\quad f^\star(x) = \sum_{i=1}^{n} \alpha_i \, k(x_i, x), \quad$ con $\alpha \in \mathbb{R}^n$.

Teorema del representante

Teorema (Kimeldorf y Wahba, 1971; Schölkopf, Herbrich y Smola, 2001)

Sea L una pérdida cualquiera y $\lambda > 0$. Todo minimizador de

$$\min_{f \in \mathcal{H}} \sum_{i=1}^{n} L\big(y_i, f(x_i)\big) + \lambda \|f\|_{\mathcal{H}}^2$$

es de la forma $f^\star(x) = \sum_{i=1}^{n} \alpha_i \, k(x_i, x)$, con $\alpha \in \mathbb{R}^n$.

Demostración. Sea $S = \text{span}\{k(x_1, \cdot), \ldots, k(x_n, \cdot)\}$ y $f = f_S + f_\perp$, con $f_\perp \perp S$.

Teorema del representante

Teorema (Kimeldorf y Wahba, 1971; Schölkopf, Herbrich y Smola, 2001)

Sea L una pérdida cualquiera y $\lambda > 0$. Todo minimizador de

$$\min_{f \in \mathcal{H}} \sum_{i=1}^{n} L\big(y_i, f(x_i)\big) + \lambda \|f\|_{\mathcal{H}}^2$$

es de la forma $\quad f^\star(x) = \sum_{i=1}^{n} \alpha_i \, k(x_i, x), \quad$ con $\alpha \in \mathbb{R}^n$.

Demostración. Sea $S = \operatorname{span}\{k(x_1, \cdot), \ldots, k(x_n, \cdot)\}$ y $f = f_S + f_\perp$, con $f_\perp \perp S$.

1. La pérdida no ve a $f_\perp$: $\quad f(x_i) = \langle f_S + f_\perp, \, k(x_i, \cdot)\rangle = f_S(x_i)$.

Teorema del representante

Teorema (Kimeldorf y Wahba, 1971; Schölkopf, Herbrich y Smola, 2001)

Sea L una pérdida cualquiera y $\lambda > 0$. Todo minimizador de

$$\min_{f \in \mathcal{H}} \sum_{i=1}^{n} L\big(y_i, f(x_i)\big) + \lambda \|f\|_{\mathcal{H}}^2$$

es de la forma $f^\star(x) = \sum_{i=1}^{n} \alpha_i \, k(x_i, x)$, con $\alpha \in \mathbb{R}^n$.

Demostración. Sea $S = \operatorname{span}\{k(x_1, \cdot), \ldots, k(x_n, \cdot)\}$ y $f = f_S + f_\perp$, con $f_\perp \perp S$.

1. La pérdida no ve a $f_\perp$: $f(x_i) = \langle f_S + f_\perp, \, k(x_i, \cdot)\rangle = f_S(x_i)$.
2. La penalización sí: $\|f\|^2 = \|f_S\|^2 + \|f_\perp\|^2$.

Teorema del representante

Teorema (Kimeldorf y Wahba, 1971; Schölkopf, Herbrich y Smola, 2001)

Sea L una pérdida cualquiera y $\lambda > 0$. Todo minimizador de

$$\min_{f \in \mathcal{H}} \sum_{i=1}^{n} L\big(y_i, f(x_i)\big) + \lambda \|f\|_{\mathcal{H}}^2$$

es de la forma $\quad f^\star(x) = \sum_{i=1}^{n} \alpha_i \, k(x_i, x), \quad$ con $\alpha \in \mathbb{R}^n$.

Demostración. Sea $S = \operatorname{span}\{k(x_1, \cdot), \ldots, k(x_n, \cdot)\}$ y $f = f_S + f_\perp$, con $f_\perp \perp S$.

1. La pérdida no ve a $f_\perp$: $\quad f(x_i) = \langle f_S + f_\perp, \, k(x_i, \cdot)\rangle = f_S(x_i)$.
2. La penalización sí: $\quad \|f\|^2 = \|f_S\|^2 + \|f_\perp\|^2$.
3. Si $f_\perp \neq 0$, reemplazar f por f_S baja estrictamente el objetivo. Luego $f^\star \in S$. $\square$

Teorema del representante

Teorema (Kimeldorf y Wahba, 1971; Schölkopf, Herbrich y Smola, 2001)

Sea L una pérdida cualquiera y $\lambda > 0$. Todo minimizador de

$$\min_{f \in \mathcal{H}} \sum_{i=1}^{n} L\big(y_i, f(x_i)\big) + \lambda \|f\|_{\mathcal{H}}^2$$

es de la forma $\quad f^\star(x) = \sum_{i=1}^{n} \alpha_i \, k(x_i, x), \quad$ con $\alpha \in \mathbb{R}^n$.

Demostración. Sea $S = \operatorname{span}\{k(x_1, \cdot), \ldots, k(x_n, \cdot)\}$ y $f = f_S + f_\perp$, con $f_\perp \perp S$.

1. La pérdida no ve a $f_\perp$: $\quad f(x_i) = \langle f_S + f_\perp,\, k(x_i, \cdot)\rangle = f_S(x_i)$.
2. La penalización sí: $\quad \|f\|^2 = \|f_S\|^2 + \|f_\perp\|^2$.
3. Si $f_\perp \neq 0$, reemplazar f por f_S baja estrictamente el objetivo. Luego $f^\star \in S$. $\square$

La clave no es $\lambda > 0$: es que la pérdida depende de f sólo a través de los valores $f(x_i)$ y la penalización crece con $\|f\|$. El problema es de dimensión infinita, pero la solución vive en un subespacio de dimensión n.

Kernel ridge y el *kernel trick*

Reemplazando $f = \sum_j \alpha_j k(x_j, \cdot)$, con $K_{ij} = k(x_i, x_j)$ la matriz de Gram de los datos ($n \times n$):

$$f(x_i) = (K\alpha)_i, \qquad \|f\|_{\mathcal{H}}^2 = \alpha^\top K \alpha.$$

$$\min_{\alpha \in \mathbb{R}^n} \sum_i L\big(y_i, (K\alpha)_i\big) + \lambda\, \alpha^\top K \alpha$$

Problema en $\mathbb{R}^n$, convexo si L lo es, porque $K \succeq 0$.

Kernel ridge y el *kernel trick*

Reemplazando $f = \sum_j \alpha_j k(x_j, \cdot)$, con $K_{ij} = k(x_i, x_j)$ la matriz de Gram de los datos ($n \times n$):

$$f(x_i) = (K\alpha)_i, \qquad \|f\|_{\mathcal{H}}^2 = \alpha^\top K \alpha.$$

$$\min_{\alpha \in \mathbb{R}^n} \sum_i L\big(y_i, (K\alpha)_i\big) + \lambda\, \alpha^\top K \alpha$$

Problema en $\mathbb{R}^n$, convexo si L lo es, porque $K \succeq 0$.

Kernel ridge (L cuadrática)

$$\nabla_\alpha = 2K\big((K+\lambda I)\alpha - y\big) = 0 \implies \alpha = (K+\lambda I)^{-1} y$$

Predicción: $f(x) = \sum_i \alpha_i\, k(x_i, x)$.

Kernel ridge y el *kernel trick*

Reemplazando $f = \sum_j \alpha_j k(x_j, \cdot)$, con $K_{ij} = k(x_i, x_j)$ la matriz de Gram de los datos ($n \times n$):

$$f(x_i) = (K\alpha)_i, \qquad \|f\|_{\mathcal{H}}^2 = \alpha^\top K \alpha.$$

$$\min_{\alpha \in \mathbb{R}^n} \sum_i L\big(y_i, (K\alpha)_i\big) + \lambda\, \alpha^\top K \alpha$$

Problema en $\mathbb{R}^n$, convexo si L lo es, porque $K \succeq 0$.

Kernel ridge (L cuadrática)

$$\nabla_\alpha = 2K\big((K+\lambda I)\alpha - y\big) = 0 \implies \alpha = (K+\lambda I)^{-1} y$$

Predicción: $f(x) = \sum_i \alpha_i\, k(x_i, x)$.

Kernel trick: si $k(x,z) = \langle \phi(x), \phi(z) \rangle$,

$$f(x) = \sum_i \alpha_i \langle \phi(x_i), \phi(x) \rangle = \Big(\underbrace{\textstyle\sum_i \alpha_i \phi(x_i)}_{w} \Big)^\top \phi(x).$$

Nunca hace falta conocer ϕ: sólo se evalúa k.

Kernels válidos ($K \succeq 0$ siempre):

- Gaussiano: $\exp\!\big(-\|x-z\|^2/2\sigma^2\big)$
- Polinomial: $(x^\top z + c)^d$, $c \geq 0$
- Laplace: $\exp(-\|x-z\|/\sigma)$

El "sigmoide" $\tanh\big(b\, x^\top z + c\big)$ no es semidefinido positivo en general. En la SVM el sesgo b no se penaliza (versión semiparamétrica del teorema). Implementación: notebook `kernel_ridge.ipynb`.

Resumen

- Reducción de dimensionalidad - PCA
- Aprendizaje no supervisado
  - Clustering geométrico - K-means
  - Clustering espectral
- Aprendizaje supervisado
  - Regresión lineal
  - Regresión logística
  - SVM - Margen óptimo

Conexión con la materia

PCA y el dual de la SVM salen de las condiciones KKT (U9); el margen de la SVM es un problema de separación (U7); k-means es un método de descenso (U4) sobre un problema no convexo.

Para leer

- von Luxburg, *A Tutorial on Spectral Clustering*.
- Hastie, Tibshirani, Friedman, *The Elements of Statistical Learning*.
- Bishop, *Pattern Recognition and Machine Learning*.
- Ng, A. *Machine Learning Yearning*.
- Murphy, K. *Probabilistic Machine Learning: An Introduction*.